

1 Dados escolhidos

Os dados utilizados no projeto foram obtidos por meio da plataforma Base dos Dados, utilizando consultas SQL executadas no Google BigQuery. Foram utilizadas informações provenientes do Censo Escolar da Educação Básica e do Índice de Desenvolvimento da Educação Básica (IDEB), produzidos pelo Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira (Inep).

No Censo Escolar, foram selecionados registros das escolas dos nove estados da Região Nordeste: Alagoas, Bahia, Ceará, Maranhão, Paraíba, Pernambuco, Piauí, Rio Grande do Norte e Sergipe. A consulta contempla atributos relacionados à identificação da escola, localização, dependência administrativa, infraestrutura física, recursos tecnológicos, materiais pedagógicos, profissionais e características das matrículas.

Para o IDEB, foram selecionadas também foram selecionadas escolas do Nordeste que possuem valor não nulo para o indicador. Os resultados das consultas foram exportados em arquivos CSV e serão posteriormente integrados utilizando o identificador da escola e o ano como principais chaves de relacionamento.

As queries utilizadas estão disponíveis no repositório.

2 Caracterização da fonte

A caracterização da fonte tem como objetivo apresentar a origem, a estrutura e as principais características dos dados utilizados no projeto. Nesta etapa, são descritos aspectos como forma de obtenção, formato dos arquivos, dimensão das bases, período de cobertura e organização das informações. Essa descrição é importante para compreender o contexto dos dados e avaliar sua adequação ao problema proposto e ao cruzamento entre o Censo Escolar e o IDEB.

Tabela Censo Escolar

Origem: Inep, disponibilizado de forma tratada pela Base dos Dados.

Forma de obtenção: consulta SQL no Google BigQuery.

Formato: arquivo CSV tabular.

Dimensão: 367.330 linhas × 50 atributos.

Distribuição temporal

Faixa temporal	Total de registros
2019–2024	478.041
2013–2018	558.486
2007–2012	521.405
Total	1.557.932

Por estado

Estado	Registros
BA	420.295
MA	262.838
CE	207.791
PE	207.476
PI	133.117
PB	119.954
RN	93.102
AL	65.617
SE	47.742

Rede administrativa

Rede	Registros
Municipal	1.171.722
Privada	242.138
Estadual	140.710
Federal	3.362

Localização

Localização	Registros
Rural	884.289
Urbana	673.643

Tabela IDEB

Origem: Inep, disponibilizado de forma tratada pela Base dos Dados.

Forma de obtenção: consulta SQL no Google BigQuery.

Formato: CSV.

Dimensão: 54.997×14 .

3 Avaliação Inicial de qualidade

A avaliação inicial da qualidade dos dados tem como objetivo identificar possíveis limitações que possam comprometer as etapas posteriores de análise e modelagem. Para isso, foram verificadas características como presença de valores ausentes, duplicidades, códigos especiais, consistência das chaves de identificação e disponibilidade das variáveis ao longo do tempo. Essa etapa é especialmente importante neste projeto, pois os dados do Censo Escolar abrangem vários anos e algumas variáveis foram incorporadas à base apenas em períodos mais recentes, o que exige cuidado para diferenciar ausência de informação de ausência real de determinada característica.

3.1 Investigando Duplicidades

Censo Escolar

Verificação	Critério	Quantidade
Linhas completamente duplicadas	Todas as colunas possuem os mesmos valores	0
Duplicidades por escola e ano	Combinação ano + id_escola repetida	0

É possível perceber que não se tem nenhum dado duplicado

IDEB

Verificação	Critério	Quantidade
Linhas completamente duplicadas	Todas as colunas possuem os mesmos valores	0
Repetições por escola e ano	Combinação ano + id_escola	2.497
Duplicidades considerando a etapa	Combinação ano + id_escola + anos_escolares	0

Com a análise podemos perceber que também não temos nenhuma fonte duplicada nessa tabela, as repetições encontradas são graças ao fator que algumas escolas possuem diferentes períodos de ensino

3.3 Ausência de dados

Os maiores percentuais são:

Campo	% ausente
tipo_situacao_funcionamento	100,0%
quantidade_matricula_utiliza_transporte_publico	92,31%
laboratorio_educacao_profissional	88,35%
profissional_assistente_social	80,46%
quantidade_profissional_pedagogia	76,42%
quantidade_profissional_psicologo	76,42%
quantidade_profissional_nutricionista	76,42%
quantidade_profissional_saude	76,42%
agua_potavel	76,42%
internet_alunos	76,42%
desktop_aluno	76,42%
materiais pedagogicos selecionados	76,42%
area_verde	45,23%
banheiro_chuveiro	45,23%
refeitorio	45,23%
biblioteca	29,95%
sala_leitura	29,95%

À primeira vista, isso parece um problema enorme de qualidade, porém fazendo uma análise um pouco mais profunda é possível perceber que existem alguns campos que não existem em todos os anos, por isso essa quantidade de campos nulos.

Ano da Primeira catalogação

Variável / grupo	Primeiro ano com dados
rede, localização, infraestrutura básica principal	2007
biblioteca e sala de leitura	2009

área verde, banheiro com chuveiro, dormitório e refeitório	2012
água potável	2019
desktop para aluno	2019
internet para alunos	2019
profissionais de saúde	2019
nutricionista	2019
psicólogo	2019
profissional de pedagogia	2019
materiais pedagógicos selecionados	2019
grêmio estudantil	2019
assistente social	2020
laboratório de educação profissional	2022
transporte público dos alunos	2023

Analisando que alguns campos surgem apenas após determinados anos é perceptível que na verdade isso representa uma **mudança do esquema do Censo Escolar ao longo do tempo**.

Valores especiais

Algumas colunas também apresentam valores com 8888, o que provavelmente é um erro

Variável	Ocorrências
quantidade_profissional_saude	447
quantidade_profissional_nutricionista	27
quantidade_profissional_psicologo	67

quantidade_profissional_pedagogia	1.048
-----------------------------------	-------

4 Dicionário mínimo

A separação dos campos em grupos foi feita para facilitar a organização e a interpretação dos dados. Assim, variáveis de **identificação e controle** ajudam a localizar e diferenciar as escolas; variáveis de **infraestrutura** representam as condições físicas e de serviços disponíveis; variáveis de **recursos pedagógicos e tecnológicos** descrevem os meios oferecidos para apoio ao ensino; variáveis de **recursos humanos** indicam a presença de profissionais especializados; e variáveis relacionadas às **matrículas** ajudam a caracterizar o perfil e o porte das escolas. Essa divisão também facilita etapas posteriores de seleção de atributos, análise exploratória e modelagem.

Identificação e controle

Campo	Significado	Tipo	Observação
ano	Ano de referência	inteiro	chave temporal
sigla_uf	Estado	categórico	variável de controle
id_municipio	Município	código	não tratar como número contínuo
id_escola	Escola	código	chave de junção
rede	Dependência administrativa	categórico	municipal, estadual etc.
tipo_localizacao	Urbana/rural	categórico	importante variável explicativa
anos_escolares	Etapa do IDEB	categórico	vem da base IDEB

Infraestrutura básica

Os valores dos campos abaixo são 0 ou 1, sendo 1 para possuindo e 0 para não possuindo.

Campo	Significado
agua_potavel	Escola possui água potável
agua_rede_publica	Água proveniente da rede pública
energia_rede_publica	Energia elétrica de rede pública
esgoto_rede_publica	Ligação à rede pública de esgoto
lixo_servico_coleta	Serviço de coleta de lixo
cozinha	Existência de cozinha
refeitorio	Existência de refeitório
banheiro_chuveiro	Existência de banheiro com chuveiro
area_verde	Existência de área verde

Infraestrutura pedagógica e tecnológica

Os valores dos campos abaixo são 0 ou 1, sendo 1 para possuindo e 0 para não possuindo.

Campo	Significado
biblioteca	Existência de biblioteca
sala_leitura	Existência de sala de leitura
laboratorio_ciencias	Laboratório de ciências
laboratorio_informatica	Laboratório de informática
quadra_esportes	Quadra de esportes
quantidade_sala_utilizada_climatizada	Quantidade de salas climatizadas utilizadas
desktop_aluno	Disponibilidade de desktop para aluno
internet_alunos	Internet disponível aos alunos

Recursos humanos

Os valores dos campos abaixo são números inteiros.

Campo	Significado
quantidade_profissional_saude	Quantidade de profissionais de saúde
quantidade_profissional_nutricionista	Quantidade de nutricionistas
quantidade_profissional_psicologo	Quantidade de psicólogos
quantidade_profissional_pedagogia	Quantidade de profissionais de pedagogia
profissional_assistente_social	Presença de assistente social

Cruzamento Tabela Censo x Tabela IDEB

A base do Censo cobre **2007–2024**, enquanto o IDEB possui dados nos anos:

2005, 2007, 2009, 2011, 2013,
2015, 2017, 2019, 2021, 2023, 2025

Os anos comuns são, portanto:

2007, 2009, 2011, 2013, 2015,
2017, 2019, 2021 e 2023

São **9 edições do IDEB** disponíveis para integração.

Resultado do cruzamento

O relacionamento foi feito por:

ano + id_escola

O uso dessa chave funciona porque no Censo existe somente uma linha para cada escola em cada ano.

Já no IDEB podem existir diferentes etapas para a mesma escola.

Correspondência por ano

Ano	Registros IDEB	Escolas distintas	Registros encontrados no Censo
2007	4.243	4.000	4.243 — 100%
2009	5.487	5.233	5.487 — 100%
2011	5.035	4.811	5.035 — 100%

2013	4.736	4.519	4.736 — 100%
2015	4.531	4.329	4.531 — 100%
2017	5.403	5.187	5.403 — 100%
2019	5.718	5.453	5.718 — 100%
2021	4.370	4.210	4.370 — 100%
2023	5.711	5.454	5.711 — 100%
Total	45.234	—	45.234 — 100%

Para o projeto vamos buscar usar os dados mais modernos de 2019 para frente, já que a partir desse ano, a maioria das colunas já começaram a ser coletadas e tem muito menos chance de serem nulas.

Amostra Utilizada

Para as primeiras aplicações do projeto, foi definido um recorte temporal composto pelos anos de **2019, 2021 e 2023**. A escolha desses anos foi feita com base na disponibilidade e na completude das variáveis do Censo Escolar, uma vez que diversos atributos relevantes para a análise, especialmente relacionados à infraestrutura, recursos tecnológicos, materiais pedagógicos e profissionais da escola, passam a apresentar maior cobertura a partir de 2019.

Além disso, esses três anos podem ser diretamente relacionados aos dados do IDEB, que possui periodicidade bienal. Dessa forma, 2019, 2021 e 2023 formam um conjunto temporal consistente entre as duas fontes, permitindo o cruzamento por `ano` e `id_escola` sem a necessidade de interpolação ou associação entre anos distintos.

Esse recorte busca equilibrar **qualidade dos dados, disponibilidade das variáveis e compatibilidade entre as fontes**, permitindo que as primeiras análises sejam realizadas sobre uma amostra mais completa e comparável. Em etapas posteriores, caso seja necessário ampliar a análise histórica, poderão ser incorporados anos anteriores com um conjunto reduzido de atributos que apresentem cobertura adequada ao longo do tempo.

5 Síntese Técnica

1. Disponibilidade dos dados.

Os dados necessários para o projeto estão disponíveis e apresentam elevada compatibilidade para integração. O Censo Escolar contém registros das escolas nordestinas entre 2007 e 2024, enquanto o arquivo do IDEB possui observações entre 2005 e 2025. Considerando os anos existentes simultaneamente nas duas fontes, é possível realizar o cruzamento para 2007, 2009, 2011, 2013, 2015, 2017, 2019, 2021 e 2023. Foram obtidas 45.234 observações de IDEB nesses anos e todas encontraram correspondência no Censo Escolar por meio das variáveis ano e id_escola.

2. Principal problema identificado.

O principal problema identificado é a mudança na disponibilidade das variáveis do Censo Escolar ao longo do tempo. Embora algumas características estejam disponíveis desde 2007, outras aparecem somente a partir de 2009, 2012, 2019, 2020, 2022 ou 2023. Dessa forma, o elevado percentual de valores ausentes em determinadas colunas não representa necessariamente falha no preenchimento, mas também alterações no esquema e nas informações coletadas pelo Censo ao longo dos anos.

3. Informações indisponíveis.

Algumas informações relevantes não estão disponíveis durante todo o período analisado. Variáveis relacionadas a profissionais de saúde, psicologia, nutrição e pedagogia, acesso à internet pelos alunos e materiais pedagógicos aparecem somente a partir de 2019. A variável de assistente social aparece a partir de 2020, enquanto a utilização de transporte público pelos estudantes está disponível somente a partir de 2023. Além disso, tipo_situacao_funcionamento encontra-se totalmente ausente na extração atual.

4. Alteração no escopo

A análise dos dados não inviabiliza o problema proposto, mas levou à definição de um recorte temporal mais específico para as primeiras aplicações do projeto. Foram selecionados os anos de **2019, 2021 e 2023**, por apresentarem maior completude das variáveis do Censo Escolar e, ao mesmo tempo, coincidirem com os anos de divulgação do IDEB, que possui periodicidade bienal.

Com essa delimitação, torna-se possível utilizar um conjunto mais amplo e detalhado de atributos, incluindo informações sobre infraestrutura, acesso à internet, profissionais especializados, materiais pedagógicos e características das matrículas, mantendo compatibilidade direta entre as duas fontes. Assim, o escopo inicial do projeto passa a priorizar uma análise mais recente e com maior riqueza de variáveis, deixando a ampliação para anos anteriores como uma possibilidade futura, caso seja necessário trabalhar com um conjunto mais reduzido e historicamente consistente de atributos.

5. Principal risco.

O principal risco relacionado aos dados é combinar períodos com estruturas de informação diferentes ou interpretar valores ausentes como ausência da característica analisada. Também

existe risco de confusão entre associação e causalidade, já que fatores como ano, estado, rede administrativa, localização da escola, etapa de ensino e tamanho da escola podem estar relacionados simultaneamente à infraestrutura disponível e ao desempenho no IDEB. Esses fatores deverão ser considerados nas etapas posteriores de análise e modelagem.